EMERSON HERRERA TOLENTINO

SOFTWARE ENGINEER · MACHINE LEARNING & GENERATIVE AI

Porto Alegre, RS, Brasil | +55 51 98128-9816
emersonheto@gmail.com | linkedin.com/in/emerson-herrera-tolentino | portfolio.certilab.app

OBJETIVO ACADÉMICO

Ingeniero de Software con más de 8 años de experiencia; desde 2025 diseño y mejoro una plataforma RAG en producción para el Banco Central de Reserva del Perú. En la maestría del PPGC – UFRGS, donde hoy curso como alumno especial, quiero investigar cómo mejorar y evaluar sistemas que combinan recuperación de información y LLMs: segmentación de documentos, recuperación y verificación de respuestas. Mi primera experiencia de investigación fue colaborar en un benchmark de modelos de visión y lenguaje aceptado en el workshop LXCV de CVPR 2026.

INTERESES DE INVESTIGACIÓN

Procesamiento de Lenguaje Natural · Large Language Models (LLMs) · Retrieval-Augmented Generation (RAG) y recuperación de información · Evaluación de LLMs y sistemas RAG · Aprendizaje por refuerzo aplicado a LLMs · Machine Learning · Sistemas multimodales · IA aplicada.

FORMACIÓN ACADÉMICA

Alumno Especial — Programa de Posgrado en Computación (PPGC)

UFRGS, Brasil · CMP263 Aprendizaje de Máquina · postulando a la maestría — *2026/2 — En curso*

Bachiller en Ingeniería de Software

UTP — Universidad Tecnológica del Perú — *2021 — 2024*

- Grado académico obtenido el 6 de febrero de 2025.

Profesional Técnico en Desarrollo de Software — carrera técnica de 3 años

SENATI — *Mar. 2016 — Jul. 2019*

FORMACIÓN COMPLEMENTARIA

Programa de Especialización en AI Engineer — Diploma de Excelencia (19/20)

Data Science Research Perú · 92 horas académicas — *Mar. 2026 — Ago. 2026*

- RAG, agentes y MCP, aplicaciones multimodales, evaluación de LLMs y LLMOps, con Diplomas de Excelencia en cinco módulos y curso de Procesamiento del Lenguaje Natural; proyecto final: sistema multiagente aplicado a procesos empresariales.

Programa de formación en Microservicios con Java y Spring Boot

Lite Thinking · curso de formación profesional — *Jun. 2024 — Sept. 2025*

IDIOMAS

Español: nativo · Portugués: intermedio (buena comprensión) · Inglés: intermedio (técnico avanzado)

PUBLICACIONES / INVESTIGACIÓN

Coautor — "Benchmark of Multimodal Vision-Language Models for Damage Detection"

LatinX in CV (LXCV) Workshop, CVPR 2026 — *Jun. 2026*

- Benchmark de CLIP, SigLIP, SigLIP2 y FuseLIP para detección de daños en desastres naturales a partir de imágenes y texto. Trabajo liderado por Mariana Risco Cosavalente, con el Prof. Claudio Jung (UFRGS).

- Extended abstract aceptado con revisión doble ciego. Mi aporte: comparación de modelos y parte de los experimentos de adaptación few-shot con CLIP sobre CrisisMMD y DamageDataset (github.com/emersonheto/damage_dataset_fewshot_vlms).

PROYECTOS

Certilab Agentic RAG — Asistente de certificados de calibración

LangGraph, FastAPI, Qdrant, OpenAI *2026*

- Servicio RAG agéntico que combina búsqueda estructurada y semántica, con fuentes citadas y control de acceso; variante Adaptive RAG de 7 nodos con dos loops de autocorrección sobre 3.848 vectores (github.com/emersonheto/certilab-agentic-rag).

EXPERIENCIA PROFESIONAL

Analista Programador II | Full Stack AI Engineer / GenAI & RAG Developer

Canvia · Perú (remoto) *Oct. 2025 — Actualidad*

- Cliente BCRP (Banco Central de Reserva del Perú): diseño, construcción y mejora de una plataforma RAG multi-tenant que atiende a 4 aplicaciones del banco (Portal BCRP, Portal de Investigación, NEXO 360 y Billetes), incluida la ingesta e indexación de miles de documentos y cientos de miles de fragmentos; su asistente está en producción en el Portal de Investigación (investigacion.bcrp.gob.pe).
- Pipelines RAG para artículos de investigación y documentos institucionales, con ingesta multimodal de PDFs e imágenes, búsqueda vectorial en Oracle 23ai, pgvector, Pinecone y Chroma, y LLMs vía OpenAI API y LangChain.

Desarrollador Full Stack y de IA (freelance)

Certilab S.A.C. · Remoto *Sept. 2024 — Actualidad*

- Sistema de certificaciones en Laravel 11 y Filament, con más de 300 certificados emitidos: backoffice administrativo, intranet donde cada cliente consulta sus certificados y portal público de validación por QR con ID cifrado.

Full Stack Developer | Angular, Java, .NET & Process Automation

Way Tech (proyectos WIN Empresas / Universidad Continental) · Perú (remoto) *Nov. 2024 — Oct. 2025*

- Desarrollo de plataformas académicas e institucionales para la Universidad Continental (más de 24.000 estudiantes en Huancayo, Arequipa, Cusco y Lima) con Angular y microservicios en C# (.NET) y Java.

Systems Engineer

Indra · San Isidro, Perú (remoto) *Mar. 2021 — Ago. 2024*

- Cliente Telefónica del Perú: sistemas distribuidos y microservicios para entornos de banca y telecomunicaciones.

Analista de Sistemas de TI

Multilab · Pueblo Libre, Perú *Feb. 2020 — Mar. 2021*

- Sistemas clínicos transaccionales con Laravel y CodeIgniter: nuevas funcionalidades, reportes y roles y permisos.

Jefe de Área de Desarrollo de Software · Software Developer

MControl Energy Technology SAC · Lima, Perú *Nov. 2017 — Ene. 2020*

- Jefe de área de desarrollo (2019 — 2020) y desarrollador (2017 — 2019): sistemas para estaciones de servicio con C#, ASP.NET, Laravel y Vue.js.

COMPETENCIAS TÉCNICAS

IA Generativa & Agentes: RAG (agéntico y adaptativo), LangChain, LangGraph, OpenAI API, Prompt Engineering, embeddings, bases de datos vectoriales (pgvector, Pinecone, Chroma, Qdrant), arquitecturas multiagente, MCP (Model Context Protocol), evaluación de LLMs y LLMOps

Machine Learning: Scikit-Learn, Pandas, NumPy, PyTorch, modelos de visión-lenguaje (CLIP, SigLIP), fine-tuning y few-shot

Investigación: comparación de modelos y experimentación (benchmark de VLMs), Jupyter, LaTeX/Overleaf

Lenguajes & Frameworks: Python (FastAPI), Java (Spring Boot), C# (.NET), Node.js, PHP (Laravel, CodeIgniter), JavaScript/TypeScript

Datos y Cloud: PostgreSQL, Oracle, MySQL, MongoDB, Redis · AWS, Azure, Docker, Kubernetes, Linux