EMERSON HERRERA TOLENTINO

SOFTWARE ENGINEER · MACHINE LEARNING & GENERATIVE AI

Porto Alegre, RS, Brasil | +55 51 98128-9816
emersonheto@gmail.com | linkedin.com/in/emerson-herrera-tolentino | portfolio.certilab.app

OBJETIVO ACADÊMICO

Engenheiro de Software com mais de 8 anos de experiência; desde 2025 projeto e aprimoro uma plataforma RAG em produção para o Banco Central de Reserva do Peru. No mestrado do PPGC – UFRGS, onde hoje curso como aluno especial, quero pesquisar como melhorar e avaliar sistemas que combinam recuperação de informação e LLMs: segmentação de documentos, recuperação e verificação de respostas. Minha primeira experiência de pesquisa foi colaborar em um benchmark de modelos de visão e linguagem aceito no workshop LXCV do CVPR 2026.

INTERESSES DE PESQUISA

Processamento de Linguagem Natural · Large Language Models (LLMs) · Retrieval-Augmented Generation (RAG) e recuperação de informação · Avaliação de LLMs e sistemas RAG · Aprendizado por reforço aplicado a LLMs · Machine Learning · Visão computacional e modelos multimodais · IA aplicada.

FORMAÇÃO ACADÊMICA

Aluno Especial — Programa de Pós-Graduação em Computação (PPGC)

UFRGS, Brasil · CMP263 Aprendizado de Máquina · candidato ao mestrado *2026/2 — Em andamento*

- Conteúdos: kNN, árvores de decisão, SVM, ensembles e avaliação de modelos (Pandas, Scikit-Learn); trabalho em grupo sobre o ENEM, responsável pelo pré-processamento.

Bacharelado em Engenharia de Software

UTP — Universidad Tecnológica del Perú *2021 — 2024*

- Grau acadêmico obtido em 6 de fevereiro de 2025.

Profissional Técnico em Desenvolvimento de Software — curso técnico superior de 3 anos

SENATI *Mar. 2016 — Jul. 2019*

FORMAÇÃO COMPLEMENTAR

Programa de Especialização em AI Engineer — Diploma de Excelência (19/20)

Data Science Research Perú · 92 horas acadêmicas *Mar. 2026 — Ago. 2026*

- RAG, agentes e MCP, aplicações multimodais, avaliação de LLMs e LLMOps, com Diplomas de Excelência em cinco módulos e curso de Processamento de Linguagem Natural; projeto final: sistema multiagente aplicado a processos empresariais.

Programa de formação em Microsserviços com Java e Spring Boot

Lite Thinking · curso de formação profissional *Jun. 2024 — Set. 2025*

IDIOMAS

Espanhol: nativo · Português: intermediário (boa compreensão) · Inglês: intermediário (técnico avançado)

PUBLICAÇÕES / PESQUISA

Coautor — "Benchmark of Multimodal Vision-Language Models for Damage Detection"

LatinX in CV (LXCV) Workshop, CVPR 2026 *Jun. 2026*

- Benchmark de CLIP, SigLIP, SigLIP2 e FuseLIP para detecção de danos em desastres naturais a partir de imagens e texto. Trabalho liderado por Mariana Risco Cosavalente, com o Prof. Claudio Jung (UFRGS).

- Resumo estendido aceito com revisão duplo-cega. Minha contribuição: comparação de modelos e parte dos experimentos de adaptação few-shot com o CLIP sobre CrisisMMD e DamageDataset (github.com/emersonheto/damage_dataset_fewshot_vlms).

PROJETOS

Certilab Agentic RAG — Assistente de certificados de calibração

LangGraph, FastAPI, Qdrant, OpenAI *2026*

- Serviço RAG agêntico que combina busca estruturada e semântica, com fontes citadas e controle de acesso; variante Adaptive RAG de 7 nós com dois loops de autocorreção sobre 3.848 vetores (github.com/emersonheto/certilab-agentic-rag).

EXPERIÊNCIA PROFISSIONAL

Analista Programador II | Full Stack AI Engineer / GenAI & RAG Developer

Canvia · Peru (remoto) *Out. 2025 — Atual*

- Cliente BCRP (Banco Central de Reserva do Peru): projeto, construção e melhoria de uma plataforma RAG multi-tenant que atende 4 aplicações do banco (Portal BCRP, Portal de Pesquisa, NEXO 360 e Cédulas), incluindo a ingestão e indexação de milhares de documentos e centenas de milhares de fragmentos; seu assistente está em produção no Portal de Pesquisa (investigacion.bcrp.gob.pe).
- Pipelines RAG para artigos de pesquisa e documentos institucionais, com ingestão multimodal de PDFs e imagens, busca vetorial em Oracle 23ai, pgvector, Pinecone e Chroma e LLMs via OpenAI API e LangChain.

Desenvolvedor Full Stack e de IA (freelance)

Certilab S.A.C. · Remoto *Set. 2024 — Atual*

- Sistema de certificações em Laravel 11 e Filament, com mais de 300 certificados emitidos: backoffice administrativo, intranet onde cada cliente consulta seus certificados e portal público de validação por QR com ID criptografado.

Full Stack Developer | Angular, Java, .NET & Process Automation

Way Tech (projetos WIN Empresas / Universidad Continental) · Peru (remoto) *Nov. 2024 — Out. 2025*

- Desenvolvimento de plataformas acadêmicas e institucionais para a Universidad Continental (mais de 24.000 estudantes em Huancayo, Arequipa, Cusco e Lima) com Angular e microsserviços em C# (.NET) e Java.

Systems Engineer

Indra · San Isidro, Peru (remoto) *Mar. 2021 — Ago. 2024*

- Cliente Telefónica del Perú: sistemas distribuídos e microsserviços para ambientes bancários e de telecomunicações.

Analista de Sistemas de TI

Multilab · Pueblo Libre, Peru *Fev. 2020 — Mar. 2021*

- Sistemas clínicos transacionais com Laravel e CodeIgniter: novas funcionalidades, relatórios e papéis e permissões.

Chefe da Área de Desenvolvimento de Software · Software Developer

MControl Energy Technology SAC · Lima, Peru *Nov. 2017 — Jan. 2020*

- Chefe da área de desenvolvimento (2019 — 2020) e desenvolvedor (2017 — 2019): sistemas para postos de combustível com C#, ASP.NET, Laravel e Vue.js.

COMPETÊNCIAS TÉCNICAS

IA Generativa & Agentes: RAG (agêntico e adaptativo), LangChain, LangGraph, OpenAI API, Prompt Engineering, embeddings, bancos de dados vetoriais (pgvector, Pinecone, Chroma, Qdrant), arquiteturas multiagente, MCP (Model Context Protocol), avaliação de LLMs e LLMOps

Machine Learning: Pandas, NumPy, modelos de visão-linguagem (CLIP, SigLIP), fine-tuning e adaptação few-shot

Pesquisa: comparação de modelos e experimentação, Jupyter, LaTeX/Overleaf

Linguagens & Frameworks: Python (FastAPI), Java (Spring Boot), C# (.NET), Node.js, PHP (Laravel, CodeIgniter), JavaScript/TypeScript

Dados e Cloud: PostgreSQL, Oracle, MySQL, MongoDB, Redis · AWS, Azure, Docker, Kubernetes, Linux